```
#IMPORTANJE
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
```

```
#UCITAVANJE PODATAKA
data = pd.read_csv("zgrade_sarajevo.csv")
# prikaz prvih 10 redova
data.head(100)
```

	grad	kvadrata	sprat	broj_soba	vrsta_grijanja	lift	parking	novogradnja	namjesten	cijena
0	Sarajevo - Stari Grad	57.00	4	2	centralno	0	0	0	2	342000
1	Sarajevo - Novi Grad	33.00	5	0	centralno	1	1	1	1	198000
2	Sarajevo - Novo Sarajevo	55.35	2	2	centralno	1	0	0	2	325000
3	Ilidža	42.00	6	2	ostalo	1	0	1	2	243600
4	Ilidža	42.00	2	1.5	struja	1	1	1	2	242960
95	Sarajevo - Centar	63.00	2	3	plin	1	1	0	2	299000
96	Sarajevo - Novi Grad	59.00	2	3	centralno	1	1	0	2	280000
97	Ilidža	51.25	5	2	centralno	1	1	1	2	243150
98	Ilidža	76.00	2	3	centralno	1	1	0	2	360000
99	Sarajevo - Centar	73.94	1	3	plin	0	0	0	1	350000

100 rows × 10 columns

Prvo ćemo uraditi OneHot encoding na gradove i vrste grijanja jer su mi to jedine kategoričke varijable.

```
#SREDIVANJE KATEGORICKIH VARIJABLI
heating_status = pd.get_dummies(data['vrsta_grijanja'])
data = pd.concat([data, heating_status], axis = 1)
data.drop(['vrsta_grijanja'], axis = 1, inplace = True)

cities_status = pd.get_dummies(data['grad'])
data = pd.concat([data, cities_status], axis = 1)
data.drop(['grad'], axis = 1, inplace = True)
```

Za spratove, pošto mnoge instance u datasetu imaju "prizemlje", "visoko", "suteren" kao sprati pošto sam poslije sa provjerom vidio da je sprat apsolutno nebitan kada se odnosi sa cijenom, samo je bitno da li je na nekom spratu ili je neka od "prizemlje", "visoko", "suteren", ako je neka od ove tri inače je niža cijena pa stavio sam da mi je sprat 1 ako je sprat a inače da je 0

```
#PRETVARANJE U BROJEVE

def sprat_map(x):
    if x in ["prizemlje", "suteren", "visoko"]:
        return 0
    if x == "20+":
        return 20
    return x

def soba_map(x):
    if x == "četverosoban":
        return 4
    return float(x)

data["sprat"] = data["sprat"].apply(sprat_map)
    data["broj_soba"] = data["broj_soba"].apply(soba_map)
```

Pošto sam za mnoge zgrade vidio da nemaju naznaku za lift, ako je na primjer neboder onda sam za zgrade sa više od 4 sprata stavio da ima lift.

```
#POSTAVLJANJE LIFTA NA TRUE AKO JE BROJ SPRATOVA VECI OD 4

data['sprat'] = pd.to_numeric(data['sprat'])

data.loc(data['sprat'] > 4, 'lift'] = 1

def poboljsanje(x):
    if x == 0:
        return 0
    return 1

data["sprat"] = data["sprat"].apply(poboljsanje)
    data.head(100)
```

	kvadrata	sprat	broj_soba	lift	parking	novogradnja	namjesten	cijena	centralno	drva	 plin	struja	Hadžići	llidža	Sarajevo - Centai
0	57.00	1	2.0	0	0	0	2	342000	1	0	 0	0	0	0	0
1	33.00	1	0.0	1	1	1	1	198000	1	0	 0	0	0	0	0
2	55.35	1	2.0	1	0	0	2	325000	1	0	 0	0	0	0	0
3	42.00	1	2.0	1	0	1	2	243600	0	0	 0	0	0	1	0
4	42.00	1	1.5	1	1	1	2	242960	0	0	 0	1	0	1	0
95	63.00	1	3.0	1	1	0	2	299000	0	0	 1	0	0	0	1
96	59.00	1	3.0	1	1	0	2	280000	1	0	 0	0	0	0	0
97	51.25	1	2.0	1	1	1	2	243150	1	0	 0	0	0	1	0
98	76.00	1	3.0	1	1	0	2	360000	1	0	 0	0	0	1	0
99	73.94	1	3.0	0	0	0	1	350000	0	0	 1	0	0	0	1

100 rows × 21 columns

Vidimo da sve sem parkinga i lifta poprilično utječe na cijenu ali i dalje i parking i lift dovoljno utječu da se razmatraju.

```
plt.figure(figsize = (16, 10))
sns.heatmap(data.corr(), annot = True, cmap="Y1GnBu")
plt.show()
```



Ovdje sam radio split na trening, test i validation, ali split je morao biti takav da za svaki dio Sarajeva posebno uradim split (pošto ilijaš ima samo 2 stana na OLX morao sam ga ukloniti iz dataseta). Taj split je 0.8 na trening_i_validaciju, 0.2 na test i onda trening_i_validaciju splitam na 0.8 za trening a 0.2 za validaciju.

```
import pandas as pd
from sklearn.model_selection import train_test_split
train_data = []
test_data = []
valid_data=[]
Y_valid=[]
Y_train = []
Y_test = []
gradovi=['Vogošća', 'Sarajevo - Stari Grad', 'Ilidža', 'Sarajevo - Novi Grad',
          'Sarajevo - Centar', 'Sarajevo - Novo Sarajevo', 'Trnovo', 'Ilijaš', 'Hadžići']
for grad in data.columns:
   if grad in gradovi:
       grad_data = data[data[grad] == 1]
       X_city = grad_data.drop('cijena', axis=1)
       y_city = grad_data['cijena']
       X_train_and_valid_city, X_test_city, Y_train_and_valid_grad, Y_test_grad = train_test_split(
           X_city, y_city,
           test_size=0.2,
           random_state=42
       print(X_train_and_valid_city.shape)
       print(grad)
       X_train_city, X_valid_city, Y_train_grad, Y_valid_grad = train_test_split(
           X_train_and_valid_city, Y_train_and_valid_grad,
           test_size=0.2,
           random_state=42
       train_data.append(X_train_city)
       test_data.append(X_test_city)
       valid_data.append(X_valid_city)
       Y_valid.append(Y_valid_grad)
       Y_train.append(Y_train_grad)
       Y_test.append(Y_test_grad)
X_train = pd.concat(train_data)
X_test = pd.concat(test_data)
X_valid = pd.concat(valid_data)
Y_train = pd.concat(Y_train)
Y_test = pd.concat(Y_test)
Y_valid = pd.concat(Y_valid)
```

```
(4, 20)
Hadžići
(165, 20)
Ilidža
(200, 20)
Sarajevo - Centar
(183, 20)
Sarajevo - Novi Grad
(156, 20)
Sarajevo - Novo Sarajevo
(66, 20)
Sarajevo - Stari Grad
(2, 20)
Trnovo
(38, 20)
Vogošća
```

Ovdje provjeravam da su veoma slične korelacije izmešu trening i testnog skupa.

```
plt.figure(figsize = (16, 10))
sns.heatmap(X_train.corr(), annot = True, cmap="YlGnBu")
plt.show()
```



```
plt.figure(figsize = (16, 10))
sns.heatmap(X_test.corr(), annot = True, cmap="YlGnBu")
plt.show()
```



Ovdje vidimo da su trening i test splitovi veoma slični

```
from scipy import stats
print(stats.describe(pd.to_numeric(Y_train)))
print(stats.describe(pd.to_numeric(Y_test)))
```

```
DescribeResult(nobs=648, minmax=(150000, 399900), mean=251090.9398148148, variance=4365594630.928366, skewness=0.45646967674069766, DescribeResult(nobs=209, minmax=(151500, 399999), mean=248200.58851674641, variance=4426977436.1856365, skewness=0.44326581607368165
```

Ovdje proširim testni dataset, povečam ga 5 puta, pokušavao sam i više i manje ali ovaj broj mi daje najbolji rezultat za linearnu regresiju pa mislim da zbog toga najbolje predstavlja dataset.

```
#Proširivanje dataseta
X_train = np.array(X_train)
Y_train = np.array(Y_train)
for i in range(len(X_train)):
   cjena_po_kvadratu = Y_train[i]/X_train[i][0]
   for j in range(-2, 4):
       if j != 0:
           nova_zgrada = X_train[i].copy()
           nova_zgrada[0] += j
           nova_cjena = nova_zgrada[0] * cjena_po_kvadratu
           X_train = np.concatenate((X_train, [nova_zgrada]))
           Y_train = np.concatenate((Y_train, [nova_cjena]))
X_test = X_test.values
Y_test = Y_test.values
Y_valid = Y_valid.values
X_{valid} = np.array(X_{valid})
```

Primjetio sam da mi je neuralna mreža bila nerealno dobra, pa sam provjeravao kakav mi je split i primjetio sam da ovom generacijom generišem oko 100 instanci koje su iste kao u testnom skupu pa njih uklonim.

```
105
```

```
X_train = np.delete(X_train, index, axis =0)
Y_train = np.delete(Y_train, index, axis =0)
print(X_train, X_train.shape)
```

Sada se uvjerim da nema istih

0

Koristio sam oba skejlara i primjetio da je minmaxScaler bolji pa njega koristim.

```
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler

train_std_scaler = StandardScaler()
X_train_std = train_std_scaler.fit_transform(X_train)
X_test_std = train_std_scaler.transform(X_test)

train_minmax_scaler = MinMaxScaler()
train_minmax_scaler = train_minmax_scaler.fit(X_train)
X_train_minmax = train_minmax_scaler.transform(X_train)
X_test_minmax = train_minmax_scaler.transform(X_test)
X_valid_minmax = train_minmax_scaler.transform(X_valid)

train_minmax_scaler = MinMaxScaler()
train_minmax_scaler.fit(Y_train.reshape(-1,1))
Y_train_minmax = train_minmax_scaler.transform(Y_train.reshape(-1,1))
Y_test_minmax = train_minmax_scaler.transform(Y_test.reshape(-1,1))
Y_valid_minmax = train_minmax_scaler.transform(Y_valid.reshape(-1,1))
```

Vidimo da obična linearna regresija daje fenomenalan rezultat

```
from sklearn.linear_model import LinearRegression
lin_reg = LinearRegression()
lin_reg.fit(X_train_minmax, Y_train_minmax)
```

▼ LinearRegression
LinearRegression()

```
from sklearn.metrics import mean_absolute_error
Y_train_pred = train_minmax_scaler.inverse_transform(lin_reg.predict(X_train_minmax))
print(mean_absolute_error(Y_train, Y_train_pred))
Y_test_pred = train_minmax_scaler.inverse_transform(lin_reg.predict(X_test_minmax))
print(mean_absolute_error(Y_test, Y_test_pred))
```

```
33756.85911278818
32540.88985046214
```

Ova neuralna mreža daje dobar rezultat, prvo postavim težine na nasumične vrijednost, zatim koristim regularzaciju L2, pokušao sam Dropout ali mi to uporpasti mrežu, previše generalizira mreža i onda slabija bude od linearne regresije. Na izlazu moram koristi sigmoid jer su mi sve vrjednosti od 0 do 1 a ako koristim RELU za aktivacijsku funckiju zakonvergira odma tako što sve vrjednosti stavi na 1. Pa sam svugdje za aktivacijsku funkciju koristio RELU. Da bi još malo poboljšo mrežu smanjujem learning rate kada zaglavi u učenju i dobijem solidan rezultat.

```
from keras.callbacks import ReduceLROnPlateau
import tensorflow as tf
alpha = 0.0001
reduce_lr = ReduceLROnPlateau(monitor='val_loss', factor=0.2,
                                                patience=5, min lr=1e-12)
init = tf.keras.initializers.RandomUniform(minval=-0.5, maxval=0.5, seed=42)
neuralna mreza = tf.keras.models.Seguential([
     tf.keras.layers.Dense(500, input_shape=(20,), kernel_initializer=init, activation="sigmoid", kernel_regularizer=tf.keras.regular
      tf.keras.layers.Dense(500, kernel initializer=init, activation="sigmoid", kernel regularizer=tf.keras.regularizers.L2(alpha)),
      tf.keras.layers.Dense(500, kernel_initializer=init, activation="sigmoid", kernel_regularizer=tf.keras.regularizers.L2(alpha)),
      tf.keras.layers.Dense(1,activation="sigmoid"),
neuralna_mreza.compile(optimizer='adam',
                      loss=tf.keras.losses.mean_absolute_error,
                      metrics=['accuracy'])
history = neuralna_mreza.fit(X_train_minmax, Y_train_minmax, batch_size=10, epochs=400, validation_data=(X_valid_minmax, Y_valid_minmax, Y_val
Epoch 399/400
Epoch 400/400
from sklearn.metrics import mean absolute error
Y train pred = train_minmax_scaler.inverse_transform(neuralna_mreza.predict(X_train_minmax))
print(mean absolute error(Y train, Y train pred))
Y_test_pred = train_minmax_scaler.inverse_transform(neuralna_mreza.predict(X_test_minmax))
print(mean_absolute_error(Y_test, Y_test_pred))
print("Predikcija: ", 100 - round((mean_absolute_error(Y_test, Y_test_pred))/Y_test.mean() * 100, 4), "%")
119/119 [======] - Os 612us/step
23170.2294760336
7/7 [======] - 0s 833us/step
26391.047772129186
Predikcija: 89.367 %
plt.plot(history.history["loss"], label='Training Loss')
plt.plot(history.history["val_loss"], label='Validation Loss')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.title('Training and Validation Loss')
plt.legend()
plt.show()
                                                                                                            png
```